

Science des données - S2 - Stat. inférentielle

TP - Échantillonnage et estimation (Moyenne, Total, Proportion)

L'objectif de ce travail à faire avec le logiciel R est de permettre d'appréhender l'incertitude et la précision de l'estimation d'une grandeur mesurable dans une population à l'aide d'un intervalle de confiance réalisé à partir d'un processus d'échantillonnage.

Ce processus d'échantillonnage se fera dans un premier temps par l'intermédiaire d'un sondage aléatoire simple à probabilités égales (tous les individus ont le même poids dans la population).

Puis dans un second temps par l'intermédiaire d'un sondage ou d'un échantillonnage par strates (ou sondage stratifié).

La confrontation de la valeur estimée avec la vraie valeur (connue par ailleurs) permettra de vérifier a posteriori la précision de l'estimation selon les deux méthodes de sondage.

Partie 1 : Estimation d'un total (nombre d'habitants). Échantillonnage aléatoire simple On

considère le jeu de données qui contient des informations sur la population belge et les revenus des habitants dans les communes. Après avoir chargé le package "sampling", les données sont disponibles ici :

```
library(sampling)
data(belgianmunicipalities)
str(belgianmunicipalities)
head(belgianmunicipalities)
```

1. Créer un data frame appelé "donnees". Afficher les 6 premières lignes de la table donnees.

```
# Data frame donnees avec les valeurs de la base
donnees = data.frame(belgianmunicipalities)
head(donnees)
```

2. La population U est l'ensemble des communes belges, les individus sont les communes.

```
# Variable U avec les communes
U = donnees$Commune
head(U)
```

3. Quel est le nombre total N de communes dans U ?

```
# Nombre de communes dans U
N = length(U)
```

4. Calculer le nombre T exact d'habitants en Belgique en 2004 (variable Tot04).

```
# nombre d'habitants en belgique en 2004
T = sum(donnees$Tot04)
```

5. On se propose d'estimer le nombre d'habitants T à partir d'un échantillon de 50 communes.

5.1. Tirer (selon un sondage aléatoire simple) un échantillon E de taille $n = 50$ de l'ensemble des communes U .

```
# Tirage aleatoire simple d'un echantillon de taille n=50
n=50
E=sample(U, n)
head(E)
```

5.2. Créer une nouvelle table contenant 2 colonnes : les communes sélectionnées et leur nombre d'habitants. Afficher les premières lignes de cette table.

```
# toutes les donnees avec les 50 communes de l'\echantillon
donnees1= donnees[donnees$Commune %in% E, ]
head(donnees1)
```

```
# L'echantillon de communes avec le nbre d'habitants dans une table
donnees2 = subset(donnees1, select=c(Commune, Tot04))
head(donnees2)
```

5.3. Calculer le nombre moyen d'habitants de l'échantillon et un IDC à 95% du nombre moyen μ d'habitants par commune.

```
# moyenne d'\echantillon
xbar= mean(donnees2$Tot04)
xbar

# IDC de \mu
idcmoy = t.test(donnees2$Tot04)$conf.int
idcmoy
```

5.4. En déduire une estimation T_{est} de T partir de l'échantillon E

```
# Nbre d'habitants total estim\ 'e
T_est = N*xbar
T_est
```

6. Quelle est la différence entre le vrai chiffre T et votre estimation T_{est} ? À quoi est due cette différence principalement? (réfléchir au processus d'échantillonnage ou à la méthode de sondage).

7. Construire un intervalle de confiance pour le nombre d'habitants T . Cet IDC contient-il la vraie valeur T ? Quelle est sa marge d'erreur?

```
# IDC de T
idcT = idcmoy*N
idcT
# marge d'erreur
marge=(idcT[2]-idcT[1])/2
marge
```

8. Refaire les questions 5, 6, 7 une dizaine de fois et illustrer les résultats à l'aide d'un tableau Excel contenant 4 colonnes (population totale T , population estimée T_{est} , IDC, marges d'erreur) et d'un graphique résumant ce tableau.

Au vu des résultats, proposer une conclusion en réfléchissant à la méthode d'échantillonnage ou de sondage.

Partie 2 : Échantillonnage aléatoire stratifié (ou sondage par strates)

Dans un sondage ou échantillonnage aléatoire simple, la sélection des individus de l'échantillon se fait totalement au hasard, et ne fait aucun usage de renseignements que l'on pourrait avoir sur les membres de la population. Ce type de sondage est adapté lorsque la population est homogène. Quand ce n'est pas le cas, si la population est divisée en plusieurs groupes exclusifs, ce type de sondage peut occulter tous les individus d'un groupe ou d'une classe.

Lorsqu'on utilise l'échantillonnage stratifié, on divise la population en groupes homogènes appelés strates qui sont mutuellement exclusifs, puis on sélectionne dans chaque strate des échantillons indépendants.

Pourquoi créer des strates? Pour bien des raisons :

- La principale étant que leur utilisation peut rendre la stratégie d'échantillonnage plus efficace.
- À l'intérieur d'une strate, les individus auraient des caractéristiques similaires qui différeraient considérablement de celles des individus inclus dans d'autres strates. On n'aurait alors besoin que d'un petit échantillon tiré de chaque strate afin d'obtenir une estimation précise de notre taille de la population.
- Un autre avantage est que l'échantillonnage aléatoire stratifié garantit que chaque sous-groupe d'une population donnée est correctement représenté au sein de l'échantillon.

Soit une population $\mathcal{P}$ structurée en sous-populations ou strates $\mathcal{P}_1, \mathcal{P}_2, \dots, \mathcal{P}_h$.

L'idée de l'échantillonnage stratifié est de diviser l'échantillon $\mathcal{E}$ en sous-échantillons $\mathcal{E}_1, \mathcal{E}_2, \dots, \mathcal{E}_H$ issus des différentes strates de la population. L'échantillon stratifié $\mathcal{E}$ est alors plus représentatif de la population.

Constitution de l'échantillon $\mathcal{E}$:

- N : taille de la population
- H : nombre de strates dans la population,
- N_h : taille de la strate $\mathcal{P}_h$: $\sum_{h=1}^H N_h = N$
- n : taille de l'échantillon $\mathcal{E}$
- n_h : taille du sous-échantillon $\mathcal{E}_h$: $\sum_{h=1}^H n_h = n$

L'échantillonnage stratifié proportionnel est caractérisé par le choix des effectifs n_h qui respectent les proportions de la population :

$$n_h = n \times \frac{N_h}{N}$$

Dans chaque strate $\mathcal{P}_h$, on effectue un échantillonnage aléatoire simple de n_h individus parmi N_h .

Estimation de la moyenne μ de la population :

- μ_h : moyenne dans la strate $\mathcal{P}_h$: $\mu_h = \frac{1}{N_h} \sum_{i \in \mathcal{P}_h} X_i$
- σ_h^2 : variance dans la strate $\mathcal{P}_h$: $\sigma_h^2 = \frac{1}{N_h - 1} \sum_{i \in \mathcal{P}_h} (X_i - \mu_h)^2$
- $\bar{X}_h$: moyenne du sous-échantillon $\mathcal{E}_h$: $\bar{X}_h = \frac{1}{n_h} \sum_{i \in \mathcal{E}_h} X_i$.
- s_h^2 : variance du sous-échantillon $\mathcal{E}_h$: $s_h^2 = \frac{1}{n_h - 1} \sum_{i \in \mathcal{E}_h} (X_i - \bar{X}_h)^2$.
- Propriétés de $\bar{X}_h$:

$$E(\bar{X}_h) = \mu_h, \quad V(\bar{X}_h) = \frac{1}{n_h} \left(1 - \frac{n_h}{N_h}\right) \sigma_h^2$$

- Estimation de la moyenne μ de la population par la moyenne des moyennes des sous-échantillons :

$$\bar{X}_{str} = \frac{1}{N} \sum_{h=1}^H N_h \bar{X}_h$$

- Propriétés de $\bar{X}_{str}$:

$$E(\bar{X}_{str}) = \mu, \quad V(\bar{X}_{str}) = \sum_{h=1}^H \left(\frac{N_h}{N}\right)^2 (1 - f_h) \frac{s_h^2}{n_h}$$

où les $f_h = n_h/N_h$ sont les taux de sondage ou d'échantillonnage dans les strates.

Ces dernières formules permettent d'obtenir un intervalle de confiance (asymptotique) pour la moyenne μ au niveau $1 - \alpha$:

$$IDC(\mu; 1 - \alpha) = \left[\bar{X}_{str} - z_{1-\alpha/2} \sqrt{V(\bar{X})}; \bar{X}_{str} + z_{1-\alpha/2} \sqrt{V(\bar{X}_{str})} \right]$$

Estimation du total T de la population

- L'estimateur du total T d'une population U par un sondage stratifié se définit par :

$$T_{str} = \sum_{h=1}^H N_h \bar{X}_h = N \bar{X}_{str}$$

T_{str} est un estimateur sans biais de T et sa variance est : $V(T_{str}) = N^2 V(\bar{X}_{str}) = \sum_{h=1}^H (N_h)^2 (1 - f_h) \frac{s_h^2}{n_h}$.

L'IDC asymptotique pour le total T au niveau $1 - \alpha$ est alors :

$$\begin{aligned} IDC(T; 1 - \alpha) &= \left[T_{str} - z_{1-\alpha/2} \sqrt{V(T_{str})} ; T_{str} + z_{1-\alpha/2} \sqrt{V(T_{str})} \right] \\ &= \left[N \bar{X}_{str} - z_{1-\alpha/2} N \sqrt{V(\bar{X}_{str})} ; N \bar{X}_{str} + z_{1-\alpha/2} N \sqrt{V(\bar{X}_{str})} \right] = N \times IDC(\mu; 1 - \alpha) \end{aligned}$$

Application : Estimation du nombre d'habitants. Échantillonnage aléatoire stratifié

On reprend le travail fait à la partie 1, en adoptant un échantillonnage stratifié.

1. On se propose de créer des strates définies par des 4 tranches de communes, des moins peuplées aux plus peuplées.

1.1. Définir les quantiles de la variable Tot04.

```
summary(donnees$Tot04)
```

1.2. Créer des strates à partir des quantiles de la var. Tot04. La nouvelle table sera nommée "datastrat" et contiendra les colonnes "Commune, Tot04, strate".

```
# strates : <5000, entre 5000 et 10000, entre 10000 et 20000, plus de 20000
donnees$strate=cut(donnees$Tot04, breaks=c(0,5000, 10000, 20000, 100000000), labels=c(1,2,3,4))
donneesstrat=donnees[ ,c("Commune", "Tot04", "strate")]
head(donneesstrat)
```

2. Tirer, selon un sondage stratifié, un échantillon E de taille $n = 50$ de communes, en prenant des effectifs dans les strates proportionnels aux poids des strates.

```
# Sondage stratifi\`e (donnees trieées par strate)
data = donneesstrat[order(donneesstrat$strate), ]
head(data)
```

```
# effectif des strates
data = donneesstrat[order(donneesstrat$strate), ]
Nh=table(data$strate)
Nh
N=sum(Nh)
N
```

```
# Poids des strates
gh=Nh/N
gh
```

```
# Tirage d'un échantillon stratifi\`e de taille n=50
n=50
```

```
nh=round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N))
```

```
nh=c(7,13,18,12)
```

```
# taux de sondage ds les strates
```

```
fh=nh/Nh
```

```
fh
```

```
# sondage strat (sans remise dans les strates)
```

```
st = strata(data, stratanames = c("strate"), size = nh, method = "srswr")
```

```
data1=getdata(data, st)
```

```
head(data1)
```

```
length((data1$Commune))
```

3. Définir les 4 sous-échantillons obtenus. Calculer les moyennes estimées des strates et leurs variances.

```
ech1=data1[data1$strate==1, ]
```

```
ech1
```

```
ech2=data1[data1$strate==2, ]
```

```
ech3=data1[data1$strate==3, ]
```

```
ech4=data1[data1$strate==4, ]
```

```
# Moyennes des 4 sous-echantillons
```

```
m1=mean(ech1$Tot04)
```

```
m2=mean(ech2$Tot04)
```

```
m3=mean(ech3$Tot04)
```

```
m4=mean(ech4$Tot04)
```

```
# Variances des 4 sous-echantillons
```

```
var1=var(ech1$Tot04)
```

```
var2=var(ech2$Tot04)
```

```
var3=var(ech3$Tot04)
```

```
var4=var(ech4$Tot04)
```

4. Calculer une estimation $\bar{X}_{st}$ du nombre d'habitants moyen μ et une estimation de la variance de $\bar{X}_{st}$.

```
# Moyenne des 4 echant reunis
```

```
Xbarst= (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4)/N
```

```
# estimation de la variance de Xbarst
```

```
varXbarst= ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2]) +  
            ((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4])
```

5. Calculer un IDC pour μ

```
# idc pour mu \ 'a 95%
```

```
alpha=0.05
```

```
binf = Xbarst - qnorm(1-alpha/2)*sqrt(varXbarst)
```

```
bsup = Xbarst + qnorm(1-alpha/2)*sqrt(varXbarst)
```

```
idcmoy=c(bin, bsup)
```

6. En déduire une estimation Tstr du nombre total d'habitants T, ainsi qu'un IDC pour T et sa marge d'erreur.

```
# estim du total T
```

```
Tstr= N*Xbarst
```

Tstr

```
# Estimation par IDC du total T
binf = idcmoy[1]*N
bsup= idcmoy[2]*N
idcT=c(binf, bsup)
idcT
```

```
# marge d'erreur
marge=(idcT[2]-idcT[1])/2
marge
```

7. Quelle est la différence entre le vrai chiffre T et votre estimation T_{str} ? Quelle est la marge d'erreur de l'IDC?

8. Refaire les questions 2 à 7 une dizaine de fois et illustrer les résultats à l'aide d'un tableau Excel contenant 4 colonnes (population totale T , population estimée T_{str} , IDC de T , marges d'erreur) et d'un graphique résumant ce tableau.

Partie 3 (Estimation d'une proportion. Sondage aléatoire simple)

La population U est l'ensemble des communes belges, les individus sont les communes et on considère le caractère X = "revenu moyen en euros par habitant en 2004" pour chaque commune (variable averageincome) :

```
library(sampling)
data(belgianmunicipalities)
donnees=data.frame(belgianmunicipalities)
head(donnees)
```

On s'intéresse à la proportion p de communes où le revenu moyen par habitant en 2004 est supérieur ou égal à 23500 euros. Pour cela, on introduit la variable binaire Y qui vaut 1 si $X \geq 23500$ et 0 sinon.

1. Créer un vecteur y contenant les valeurs de Y pour toutes les communes. En déduire la valeur exacte de la proportion p et commenter cette valeur.

```
# creation de la var binaire y
U = belgianmunicipalities$Commune
X=belgianmunicipalities$averageincome
y <- ifelse(X >= 23500, 1, 0)
```

```
# vraie valeur de la proportion p
p = mean(y)
p
```

2. Quel est le nombre total de communes (taille de la population)? Quel est le nombre de communes dont le revenu moyen par habitant est supérieur ou égal à 23500 euros?

```
# nbre total de communes
N=length(U)
N
# nbre de communes dont le revenu est >= 23500
sum(y)
```

3. Créer une table avec les communes, leur nombre d'habitants, leur revenu et la variable Y .

```
# table avec y
donnees2 = cbind(donnees, y)
```

```
head(donnees2)
donnees3=donnees2[c("Commune", "Tot04", "averageincome", "y")]
head(donnees3)
```

4. Sélectionner un échantillon de 50 communes suivant un sondage aléatoire simple. Créer un tableau des données des communes sélectionnées.

```
# echantillon alea. simple
n=50
echantillon <- sample(donnees3$Commune, n)
echantillon

# tableau de donnees des 50 communes de l'échantillon
donneesech <- donnees3[donnees3$Commune %in% echantillon, ]
head(donneesech)
```

5. Proposer une estimation f_n de p à partir de l'échantillon sélectionné et construire un intervalle de confiance pour p au niveau 95%. Est-ce que cet intervalle contient p ? Quelle est sa marge d'erreur?

```
# estimation de p
f=mean(donneesech$y)
f

# idc de p
alpha=0.05
z=qnorm(1-alpha/2)
binf=f-z*sqrt(f*(1-f)/n)
bsup=f + z*sqrt(f*(1-f)/n)
idcp=cbind(binf, bsup)
idcp

# marge d'erreur
marge=(bsup-binf)/2
marge
```

6. Refaire les questions 4 et 5 une dizaine de fois et illustrer les résultats à l'aide d'un tableau Excel contenant 4 colonnes (vraie proportion p , proportion estimée f_n , IDC, marges d'erreur) et d'un graphique résumant ce tableau.

Partie 4 : Estimation d'une proportion. Échantillonnage aléatoire stratifié

On reprend le travail fait à la partie 3, en adoptant un échantillonnage stratifié.

1. Créer des strates à partir des quantiles de la var. Tot04 dans la table donnees3. La nouvelle table nommée donneesstrat contiendra les colonnes "Commune, Tot04, averageincome, y, strate".

```
# Estimation d'une proportion. Sondage stratifié
head(donnees)
head(donnees3)
summary(donnees3$Tot04)

# strates : <5000, entre 5000 et 10000, entre 10000 et 20000, plus de 20000
donnees3$strate=cut(donnees3$Tot04, breaks=c(0,5000, 10000, 20000, 100000000), labels=c(1,2,3,4))
head(donnees3)

# donnees stratifiées
```

```
donneesstrat=donnees3[c("Commune", "Tot04", "averageincome", "strate", "y")]
head(donneesstrat)
```

2. Construire une table croisant les variables Y et “strate” et effectuer le test du khi-deux en affichant les contributions. Commenter les résultats.

```
# test du khi2 entre les var y et strate
table=table(donneesstrat$y, donneesstrat$strate)
chisq.test(table)
```

```
# contributions
chisq.test(table)$residuals^2
```

3. Tirer, selon un sondage stratifié, un échantillon E de taille $n = 50$ de communes, en prenant des effectifs n_h proportionnels aux tailles N_h des strates.

```
# effectifs des strates
data=donneesstrat[order(donneesstrat$strate), ]
head(data)
Nh=table(data$strate)
Nh

# poids des strates
gh=Nh/N
gh

# Tirage d'un echantillon stratifi\`e de taille n=50
n=50
# effectif des sous-echantillons
nh=round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N))
nh # probleme : la somme ne fait pas 50 !
nh=c(8,14,17,11)
```

```
# sondage strat
st = strata(data, stratanames = c("strate"), size = nh, method = "srswr")
data1=getdata(data, st)
```

4. Définir les 4 sous-échantillons obtenus. Calculer les fréquences observées f_n dans les sous-échantillons

```
ech1=data1[data1$strate==1, ]
ech1
ech2=data1[data1$strate==2, ]
ech3=data1[data1$strate==3, ]
ech4=data1[data1$strate==4, ]

# frequences obs sur les 4 sous-echantillons
f1=mean(ech1$y)
f2=mean(ech2$y)
f3=mean(ech3$y)
f4=mean(ech4$y)
```

5. Calculer une estimation f_{str} de la proportion p en considérant les moyennes pondérées des fréquences observées. Calculer sa variance.

```
# frequence obs sur l'echantillon : estimation de p
f_str= (Nh[1]*f1 + Nh[2]*f2 + Nh[3]*f3 + Nh[4]*f4)/N
f_str
```

```
# estimation de la variance de f_str
varf_str= (gh[1])^2*f1*(1-f1)/(nh[1]-1) + (gh[2])^2*f2*(1-f2)/(nh[2]-1) +
  (gh[3])^2*f3*(1-f3)/(nh[3]-1) + (gh[4])^2*f4*(1-f4)/(nh[4]-1)
```

6. Calculer un IDC pour p à 95%, ainsi que sa marge d'erreur.

```
# idc pour p
alpha=0.05
binf = f_str - qnorm(1-alpha/2)*sqrt(varf_str)
bsup = f_str + qnorm(1-alpha/2)*sqrt(varf_str)
idcp=c(binf, bsup)
idcp
```

```
# marge d'erreur
marge=(idcp[2]-idcp[1])/2
marge
```

7. Refaire les questions 2 à 5 une dizaine de fois et illustrer les résultats à l'aide d'un tableau Excel contenant 4 colonnes (vraie proportion p , proportion estimée f_{str} , IDC, marges d'erreur) et d'un graphique résumant ce tableau.